# AgriTech

## دليل فهم البيانات · التنظيف · بناء الموديل

قاعدة بيانات SQL Server: [AgriTech]

مصر (FAOSTAT) + دول العالم (World Bank) + المناخ الشهري — الفترة 2000 إلى 2024

| 10 | 8 | 5 + 4 | 25 |
|---|---|---|---|
| جداول خام (Raw) | جداول منظّفة (Clean) | Dimensions + Facts | سنة (2000–2024) |

تاريخ الإعداد: 30 سبتمبر 2026

مبني على سكريبت Full Build Script (النسخة الأخيرة المرفوعة)

# الفهرس


**1. نظرة عامة على المشروع** **3**

1.1 المشروع في جملتين 3

1.2 مصادر البيانات العشرة 3

1.3 رحلة البيانات: من الخام إلى الموديل 3

1.4 مصطلحات لازم نتفق عليها 4

**2. فهم البيانات: كل جدول بيعبّر عن إيه** **5**

2.1 `FAOSTAT_data_en_2-23-2026` — محاصيل ومنتجات مصر 5

2.2 `Irrigated Land_data_en_2-24-2026` — الري في مصر 7

2.3 `Rainfall_Monthly_2000_2024` — المطر الشهري 7

2.4 `Temperature at 2 Meters_2000_2024` — الحرارة الشهرية 8

2.5 مؤشرات البنك الدولي الأربعة 8

2.6 `Metadata_Country_API_SP.POP.TOTL_DS2_en_csv_v2_40826` — تصنيف الدول 9

2.7 `Dim_Soil_Properties` — ملخص خصائص التربة 9

2.8 إزاي المصادر بتترابط ببعض؟ 10

**3. التنظيف: عملنا إيه ولية** **11**

3.1 القواعد الثلاث اللي ماشيين عليها 11

3.2 ملخص قبل وبعد 11

3.3 الخطوات واحدة واحدة 11

3.4 قرارات اخترنا فيها "ما نعملش" 13

3.5 تنبيهات تخص التنظيف 13

**4. الموديل: اتبنى إزاي (أهم جزء)** **14**

4.1 الفكرة: ليه Galaxy Schema؟ 14

4.2 خطوات التصميم الأربعة 14

4.3 شكل الموديل (الصفحة التالية) 14

4.4 الجداول واحد واحد 16

4.5 العلاقات (Foreign Keys) 19

4.6 ترتيب البناء ولية بالترتيب ده 19

4.7 قرارات التصميم ولية 20

4.8 التحقق وأمثلة استعلامات 21

4.9 الاستخدام في التحليل (وأدوات BI مثل Power BI) 22

4.10 الافتراضات والقيود 22

**5. ملحق** **24**

5.1 الكود الأساسي لأهم جداول الموديل 24

5.2 ملاحظات قبل تشغيل السكريبت 25

# 1. نظرة عامة على المشروع

## 1.1 المشروع في جملتين

مشروع **AgriTech** بيربط الزراعة المصرية (المحاصيل والأراضي المروية) بالمناخ الشهري (المطر ودرجة الحرارة) وبمؤشرات الدول (السكان، الأراضي الصالحة للزراعة، الأسمدة، انبعاثات الزراعة). بياخد ملفات خام متفرقة، ينظّفها، ويرتّبها في **موديل بيانات** نظيف وجاهز للتحليل.

الفترة المطلوبة في كل الجداول المنظّفة: **من 2000 إلى 2024** (25 سنة).

## 1.2 مصادر البيانات العشرة

أرقام الصفوف مأخوذة من ملفات الـ CSV الأصلية.

| # | اسم الجدول في SQL | الموضوع والمصدر | التغطية | الصفوف | الفترة |
|---|---|---|---|---|---|
| 1 | `FAOSTAT_data_en_2-23-2026` | FAOSTAT — المحاصيل والمنتجات الحيوانية (المجال QCL) | مصر | 22,568 | 1961–2024 |
| 2 | `Irrigated Land_data_en_2-24-2026` | FAOSTAT — استخدام الأراضي: الري (المجال RL) | مصر | 53 | 2000–2023 |
| 3 | `Rainfall_Monthly_2000_2024` | المناخ — مجموع المطر الشهري (`PRECTOTCORR_SUM`) | شبكة 266 نقطة | 79,800 | 2000–2024 |
| 4 | `Temperature at 2 Meters_2000_2024` | المناخ — حرارة الهواء على ارتفاع 2 متر (`T2M`) | نفس الشبكة | 79,800 | 2000–2024 |
| 5 | `Arable Land` | World Bank — الأراضي الصالحة للزراعة (% من مساحة الأرض) | 254 كود | 14,847 | 1961–2023 |
| 6 | `CO₂ Emissions` | World Bank — انبعاثات CO2 من الزراعة (Mt CO2e) | 156 كود | 8,580 | 1970–2024 |
| 7 | `Fertilizer Use` | World Bank — استهلاك الأسمدة (kg لكل هكتار أرض صالحة) | 248 كود | 12,688 | 1961–2023 |
| 8 | `Population` | World Bank — إجمالي السكان | 265 كود | 17,195 | 1960–2024 |
| 9 | `Metadata_Country_API_SP.POP...` | World Bank — تصنيف الدول (Region و IncomeGroup) | 265 كود | 265 | — |
| 10 | `Dim_Soil_Properties` | ملخص إحصائي لخمس خصائص للتربة | — | 5 | — |

> **ملاحظة عن مصدر المناخ**
>
> الملفين مالهمش عمود مصدر، لكن أسماء المتغيرات (`PRECTOTCORR` و `T2M`) هي نفس أسماء متغيرات مشروع NASA POWER. فده استنتاج من الأسماء، مش معلومة مكتوبة في الملف.

## 1.3 رحلة البيانات: من الخام إلى الموديل

كل مصدر بيعدّي على 3 مراحل. المرحلة الأولى (Raw) ما بنلمسهاش أبدًا. المرحلة التانية (Clean) نسخة منظّفة. المرحلة التالتة (Model) جداول مرتّبة للتحليل.

| ① الخام (Raw) | ② المنظّف (Clean) | ③ الموديل (Model) |
|---|---|---|
| `FAOSTAT_data_en_2-23-2026` | `clean_FAOSTAT_data` | `Fact_Crops` + `Dim_Item` |
| `Irrigated Land_data_en_2-24-2026` | `clean_Irrigated_Land` | `Fact_Irrigated` |
| `Rainfall_Monthly_2000_2024` | `clean_Rainfall_Monthly` | `Dim_Location` + `Fact_Climate` |
| `Temperature at 2 Meters_2000_2024` | `clean_Temperature_at2Meters` | `Dim_Location` + `Fact_Climate` |
| `Arable Land` | `clean_Arable_Land` | `Fact_Country_Year` |
| `CO₂ Emissions` | `clean_CO2Emissions` | `Fact_Country_Year` |
| `Fertilizer Use` | `clean_Fertilizer_Use` | `Fact_Country_Year` |
| `Population` | `clean_Population` | `Fact_Country_Year` + أسماء الدول في `Dim_Country` |
| `Metadata_Country_API_SP.POP...` | (بدون Clean — بيتقرا مباشرة) | `Dim_Country` |
| (بيتولّد بالكود) | — | `Dim_Year` + `Calendar` |
| `Dim_Soil_Properties` | — | خارج الموديل (مفيش ربط بالسنة أو الموقع) |

## 1.4 مصطلحات لازم نتفق عليها

| المصطلح | المعنى ببساطة | مثال من مشروعنا |
|---|---|---|
| Grain (مستوى التفصيل) | الصف الواحد في الجدول بيمثّل إيه بالظبط؟ | في `Fact_Crops`: محصول واحد في سنة واحدة |
| Dimension | جدول بيوصف "مين / إيه / إمتى / فين"، والصف فيه بيتكرر مرة واحدة بس | `Dim_Country`، `Dim_Item`، `Dim_Year` |
| Fact | جدول القياسات الرقمية (Measures) بمستوى تفصيل محدد | `Fact_Crops`: مساحة، إنتاجية، إنتاج |
| (PK) Primary Key | العمود (أو مجموعة أعمدة) اللي بيميّز كل صف عن غيره، ومش بيتكرر | `Item_ID` في `Dim_Item` |
| (FK) Foreign Key | عمود بيشاور على PK في جدول تاني، وقاعدة البيانات بترفض أي قيمة مالهاش أصل | `Fact_Crops.Item_ID` ← `Dim_Item.Item_ID` |
| Long format / Wide format | Long: كل قياس في صف. Wide: كل قياس في عمود | FAOSTAT جاي Long، و `Fact_Crops` بنيناه Wide |
| NULL | مفيش قيمة (مجهولة) — غير الصفر تمامًا | 24 صف في FAOSTAT قيمتهم NULL |

# 2. فهم البيانات: كل جدول بيعبّر عن إيه

لكل جدول: **بطاقة تعريف** (المصدر، التغطية، الـ Grain)، بعدها **شرح الأعمدة**، وأخيرًا **ملاحظات الجودة**. القيم والأمثلة كلها من الملفات الفعلية.

## 2.1 `FAOSTAT_data_en_2-23-2026` — محاصيل ومنتجات مصر

| | |
|---|---|
| **المصدر** | FAOSTAT (منظمة الأغذية والزراعة). المجال (Domain) اسمه Crops and livestock products وكوده QCL |
| **التغطية** | مصر فقط: `Area_Code_M49 = 818` |
| **الحجم** | 22,568 صف — من 1961 إلى 2024 |
| **الـ Grain** | صف واحد لكل (Year × Element × Item) |
| **الشكل** | Long format: نوع القياس في عمود `Element` ووحدته في `Unit` وقيمته في `Value` |

### الأعمدة (14 عمود في جدول SQL)

| العمود | النوع (من الملف) | المعنى | مثال |
|---|---|---|---|
| `Domain_Code` | نص | كود المجال | `QCL` |
| `Domain` | نص | اسم المجال | Crops and livestock products |
| `Area_Code_M49` | رقم | كود الدولة بترميز الأمم المتحدة M49 | 818 |
| `Area` | نص | اسم الدولة | Egypt |
| `Element_Code` | رقم | كود **نوع القياس** (أهم عمود لفهم الجدول) | 5312 |
| `Element` | نص | اسم نوع القياس | Area harvested |
| `Item_Code_CPC` | نص | كود المنتج حسب تصنيف CPC | 111 |
| `Item` | نص | اسم المنتج (محصول، أو منتج مصنّع/حيواني) | Wheat |
| `Year_Code` | رقم | كود السنة (نفس قيمة `Year`) | 2024 |
| `Year` | رقم | السنة | 2024 |
| `Unit` | نص | وحدة القياس | `ha` |
| `Value` | رقم | القيمة نفسها | 1,386,892 |
| `Flag` | نص | رمز مصدر/جودة القيمة | `A` |
| `Flag_Description` | نص | شرح الرمز | Official figure |

> **عمود `Note` مش في جدول SQL**
>
> ملف الـ CSV فيه عمود خامس عشر اسمه `Note` (قيمته Unofficial figure في 454 صف)، لكن مش موجود في الجدول اللي عندك في SQL Server. ده اللي اتأكدنا منه من قايمة الأعمدة اللي ظهرت في SSMS.

### يعني إيه Element؟ (أهم فكرة في الجدول)

الجدول فيه **14 نوع قياس** مختلف، كل واحد ليه وحدة. لو جمعنا عمود `Value` كله مع بعض هنجمع هكتارات مع أطنان مع أعداد حيوانات، وده غلط. عشان كده أول قرار في التنظيف هو اختيار أنواع القياس اللازمة.

| Element_Code | Element | Unit | الصفوف (كل السنين) | بنستخدمه؟ |
|---|---|---|---|---|
| 5312 | Area harvested<br>المساحة المحصودة | ha | 4,812 | ✓ نعم |
| 5412 | Yield<br>الإنتاجية | kg/ha | 4,562 | ✓ نعم |
| 5510 | Production<br>الإنتاج | t | 8,616 | ✓ نعم |
| 5111 | Stocks<br>أعداد حيوانات | An | 576 | ✗ لا |
| 5112 | Stocks | 1000 An | 354 | ✗ لا |
| 5114 | Stocks<br>(نحل) | No | 64 | ✗ لا |
| 5313 | Laying | 1000 An | 64 | ✗ لا |
| 5318 | Milk Animals | An | 256 | ✗ لا |
| 5320 | Producing Animals/Slaughtered | An | 1,408 | ✗ لا |
| 5321 | Producing Animals/Slaughtered | 1000 An | 384 | ✗ لا |
| 5413 | Yield | No/An | 64 | ✗ لا |
| 5417 | Yield/Carcass Weight | kg/An | 896 | ✗ لا |
| 5424 | Yield/Carcass Weight | g/An | 448 | ✗ لا |
| 5513 | Production | 1000 No | 64 | ✗ لا |

## الـ Flag: يعني إيه؟

| Flag | Flag_Description | الصفوف (كل الجدول) |
|---|---|---|
| A | Official figure<br>رقم رسمي | 14,402 |
| E | Estimated value<br>قيمة تقديرية | 4,916 |
| I | Value imputed by a receiving agency<br>قيمة معوّضة من جهة مستقبِلة | 2,480 |
| X | Figure from external organization<br>رقم من منظمة خارجية | 482 |
| M | Missing value; data cannot exist<br>قيمة مفقودة | 288 (هما نفس صفوف Value = NULL) |

## مثال حقيقي: القمح سنة 2024

| Element | Unit | Value |
|---|---|---|
| Area harvested | ha | 1,386,892 |
| Yield | kg/ha | 6,777.7 |
| Production | t | 9,400,000 |

الأرقام متّسقة: 1,386,892 هكتار × 6,777.7 كجم/هكتار ≈ 9.4 مليون طن.

**نقاط جودة لازم نعرفها**

- فيه **62 صنف** مش محاصيل (لبن، جبن، زبدة، لحوم، زيوت، مشروبات...). ليهم قياس Production فقط، من غير مساحة أو إنتاجية.
- الأصناف اللي ليها مساحة وإنتاجية = **78 محصول** فقط. الإجمالي بعد اختيار الـ 3 أنواع = **140 صنف**.
- الإنتاجية Yield ما ينفعش تتجمع أو تتوسّط بالمتوسط البسيط بين المحاصيل. بتتحسب من الإنتاج ÷ المساحة.

## 2.2 `Irrigated Land_data_en_2-24-2026` — الري في مصر

| | |
|---|---|
| **المصدر** | FAOSTAT. المجال (Domain) اسمه Land Use وكوده RL |
| **التغطية** | مصر فقط |
| **الحجم** | 53 صف — من 2000 إلى 2023 (الملف نفسه بيقف عند 2023) |
| **الـ Grain** | صف واحد لكل (Year × Element × Item) |
| **البنية** | نفس أعمدة FAOSTAT، مع اختلاف إن كود المنتج اسمه `Item_Code` بدل `Item_Code_CPC` |

| `Element_Code` | `Element` | `Unit` | `Item` | الصفوف | السنين |
|---|---|---|---|---|---|
| 5110 | Area<br>المساحة | `1000 ha` | Land area equipped for irrigation<br>مساحة مجهّزة للري | 24 | 2000–2023 |
| 5110 | Area | `1000 ha` | Land area actually irrigated<br>مساحة اتروت فعلًا | 5 | 2019–2023 |
| 7252 | Share in Cropland<br>النسبة من الأراضي المحصولية | `%` | Land area equipped for irrigation | 24 | 2000–2023 |

مثال: سنة 2023 مساحة الأرض المجهّزة للري = **4,013.7053 ألف هكتار**. والـ Flags في الجدول: (2) X · (22) I · (22) E · (7) A. مفيش قيم فاضية.

**ملاحظة على التغطية**

قياس "المساحة المروية فعلًا" موجود لـ 5 سنين بس (2019–2023)، عكس "المجهّزة للري" اللي عندها 24 سنة كاملة. أي مقارنة بين الاتنين لازم تحترم الفرق ده.

## 2.3 `Rainfall_Monthly_2000_2024` — المطر الشهري

| | |
|---|---|
| **المحتوى** | مجموع المطر الشهري (`PARAMETER = PRECTOTCORR_SUM`) لكل نقطة في شبكة جغرافية |
| **الحجم** | 79,800 صف = 266 موقع × 25 سنة × 12 شهر |
| **الشبكة** | 19 خط عرض (من 22.5 إلى 31.5) × 14 خط طول (من 25.625 إلى 33.75) = 266 نقطة، بدقة 0.5° × 0.625° |
| **الـ Grain** | صف واحد لكل (Month × Year × Location) |

| العمود | النوع في SQL | المعنى | مثال |
|---|---|---|---|
| `PARAMETER` | nvarchar | اسم المتغير (قيمة واحدة ثابتة) | `PRECTOTCORR_SUM` |
| `YEAR` | int | السنة | 2000 |

| العمود | النوع في SQL | المعنى | مثال |
|---|---|---|---|
| `LAT` | float | خط العرض | 22.5 |
| `LON` | float | خط الطول | 25.625 |
| `Month` | nvarchar | اختصار الشهر بالإنجليزي (`JAN` ... `DEC`) | `JAN` |
| `Rainfall` | float | قيمة المطر للشهر | 0.0599999986588955 |

**إحصائيات ولاحظات**

- متوسط القيمة 2.65، وأعلى قيمة 592.58، و **54.8%** من القيم صفر (شهور جافة). ده طبيعي لمناخ مصر الجاف.
- أعلى 5 قيم كلها في **مارس 2021** على خط عرض 30.5 إلى 31.5 (الساحل الشمالي الغربي). القيم دي استثنائية وبنسيبها زي ما هي، بس تستاهل مراجعة قبل أي استنتاج عن المطر.
- **الوحدة مش مكتوبة في الملف.** احنا سمّينا العمود `Rainfall_mm` على افتراض إنها ملّيمتر.

## 2.4 `Temperature at 2 Meters_2000_2024` — الحرارة الشهرية

| | |
|---|---|
| **المحتوى** | متوسط حرارة الهواء على ارتفاع 2 متر (`PARAMETER = T2M`) |
| **الحجم** | 79,800 صف — نفس الشبكة ونفس السنين ونفس الأشهر |
| **الأعمدة** | نفس أعمدة الـ Rainfall، والفرق إن العمود الأخير اسمه `Temperature` |
| **الـ Grain** | صف واحد لكل (Month × Year × Location) |

متوسط الحرارة 22.3 وأقل قيمة 5.85 وأعلى قيمة 37.74. مفيش قيم فاضية ولا تكرار. **الوحدة مش مكتوبة**، واحنا سمّينا العمود `Temperature_C` لأن القيم متوافقة مع الدرجة المئوية.

**أهم حقيقة عن الجدولين**

مفتاح الجدولين واحد: (YEAR, LAT, LON, Month). لما ربطناهم بالأربع أعمدة دول ظهر **79,800 صف مطابق** من كل جدول، يعني علاقة 1 ↔ 1 كاملة. وده اللي بيسمح ندمجهم في جدول Fact_Climate واحد.

## 2.5 مؤشرات البنك الدولي الأربعة

أربع جداول ليهم **نفس البنية بالظبط**: كل صف = قيمة مؤشر واحد لدولة (أو تجمّع) في سنة. الفرق الوحيد هو اسم عمود القيمة.

| العمود المشترك | المعنى | مثال |
|---|---|---|
| `Country_Name` | اسم الدولة/التجمّع | Egypt, Arab Rep. |
| `Country_Code` | كود الدولة (3 حروف) | `EGY` |
| `Indicator_Name` | اسم المؤشر (قيمة واحدة ثابتة في كل جدول) | Population, total |
| `Indicator_Code` | كود المؤشر | `SP.POP.TOTL` |
| `Year` | السنة | 2024 |
| عمود القيمة | يختلف حسب الجدول (تحت) | — |

| الجدول | عمود القيمة في SQL | المؤشر والوحدة | الأكواد | الصفوف | السنين | مثال لمصر |
|---|---|---|---|---|---|---|
| `Arable Land` | `Arable_land_percent` | أراضي صالحة للزراعة، % من مساحة الأرض | 254 | 14,847 | 1961–2023 | (2023) 3.12 |

| الجدول | عمود القيمة في SQL | المؤشر والوحدة | الأكواد | الصفوف | السنين | مثال لمصر |
|---|---|---|---|---|---|---|
| `CO₂ Emissions` | `CO_Emissions` | انبعاثات CO2 من الزراعة، Mt CO2e | 156 | 8,580 | 1970–2024 | 2.5236 (2024) |
| `Fertilizer Use` | `Fertilizer_consumption` | استهلاك الأسمدة، kg لكل هكتار أرض صالحة | 248 | 12,688 | 1961–2023 | 532.77 (2023) |
| `Population` | `Population` | إجمالي السكان | 265 | 17,195 | 1960–2024 | 116,538,258 (2024) |

**ملاحظات**

- اسم عمود الانبعاثات في الملف الأصلي هو `CO₂ Emissions`، وفي SQL بقى `CO_Emissions` (الرمز ₂ اتشال وقت الاستيراد).
- مفيش قيم فاضية ولا تكرار داخل الجداول الأربعة. لكن **تغطيتها مختلفة**: الانبعاثات لـ 156 كود فقط، وآخر سنة للأراضي والأسمدة 2023.
- الجداول بتضم **تجمّعات** مش دول بس (مثل `WLD` = العالم)، وده سبب إن عدد الأكواد أكتر من عدد دول العالم.
- `Population` هو الأشمل: **265 كود** وكل السنين، وعلى أساسه بنينا `Fact_Country_Year`.

## 2.6 `Metadata_Country_API_SP.POP.TOTL_DS2_en_csv_v2_40826` — تصنيف الدول

| | |
|---|---|
| **المحتوى** | جدول تعريفي: كل كود دولة وتصنيفه |
| **الحجم** | 265 صف = **217 دولة** + **48 تجمّع** (مجموعات إقليمية وتصنيفات دخل مثل `WLD`) |
| **الـ Grain** | صف واحد لكل `Country_Code` |

| العمود | المعنى | ملاحظة |
|---|---|---|
| `Country_Code` | كود الدولة/التجمّع | المفتاح المشترك مع الجداول الأربعة |
| `Region` | الإقليم (7 قيم) | فاضي لـ 48 تجمّع |
| `IncomeGroup` | فئة الدخل (4 قيم) | فاضي لـ 50 كود: التجمّعات الـ 48 + إثيوبيا `ETH` + فنزويلا `VEN` |
| `SpecialNotes` | ملاحظات نصية | مش مستخدم في الموديل |
| `TableName` | الاسم المختصر للدولة | مثال: Egypt, Arab Rep. |

| قيمة `IncomeGroup` | عدد الأكواد |
|---|---|
| High income | 86 |
| Upper middle income | 54 |
| Lower middle income | 50 |
| Low income | 25 |
| (فاضي) | 50 (48 تجمّع + `ETH` + `VEN`) |

تصنيف مصر: الإقليم Middle East & North Africa، وفئة الدخل Lower middle income.

## 2.7 `Dim_Soil_Properties` — ملخص خصائص التربة

جدول صغير (5 صفوف)، كل صف = خاصية تربة واحدة بإحصائياتها. مفيهوش سنة ولا موقع.

| File | Property | Mean | Min | Max | Std |
|---|---|---|---|---|---|
| organic_carbon | الكربون العضوي | 21.25 | 2 | 131 | 15.88 |
| organic_Nitrogen | النيتروجين العضوي | 0.79 | 0.154 | 2.74 | 0.33 |
| organic_potassium | البوتاسيوم العضوي | 1.04 | 0.265 | 3.18 | 0.34 |
| organic_PH | درجة حموضة التربة | 72.82 | 58 | 89 | 3.90 |
| organic_Texture | قوام التربة | 5.35 | 1 | 9 | 1.68 |

**ملاحظتان (استنتاج مش معلومة مؤكدة)**

قيم الحموضة (58–89) شكلها مضروبة في 10 (يعني 5.8 إلى 8.9)، وقوام التربة (1–9) شكله رمز تصنيف مش قياس مستمر. الملف ما بيوضّحش ده، فلازم يتأكد من مصدر الجدول قبل الاستخدام.

## 2.8 إزاي المصادر بتترابط ببعض؟

| المفتاح | بيربط إيه؟ | ملاحظات |
|---|---|---|
| YEAR / Year | كل الجداول | المفتاح الزمني المشترك، وبيتحوّل في الموديل إلى YearNumber |
| Country_Code | الأربع جداول العالمية + Metadata | كود مصر هو EGY . جداول FAOSTAT ما فيهاش Country_Code ، وبدله فيها Area_Code_M49 (قيمته 818 لمصر)، واحنا بنثبّت EGY في الموديل |
| Item | جدول FAOSTAT بس | مفيش أصناف مشتركة مع جدول الري |
| (YEAR, LAT, LON, Month) | Rainfall ↔ Temperature | مطابقة 79,800 من 79,800 |
| Year فقط | FAOSTAT ↔ الري ↔ المناخ ↔ الدول | مفيش مفتاح أدق. عشان كده أي مقارنة بينهم بتتم على مستوى السنة |

# 3. التنظيف: عملنا إيه ولية

## 3.1 القواعد الثلاث اللي ماشيين عليها

| القاعدة | إزاي اتنفذت | ليه؟ |
|---|---|---|
| **الجدول الخام ما بيتلمسش** | كل تنظيف بيتعمل في جدول جديد اسمه `clean_...` بأمر `SELECT ... INTO` | لو حصل غلط نرجع للأصل من غير ما نعيد الاستيراد |
| **السكريبت يتشغّل أكتر من مرة** | `DROP TABLE IF EXISTS` قبل كل إنشاء + `GO` بين الأقسام | أي تعديل نعيد تشغيل السكريبت كله من أوله وبنفس النتيجة |
| **ما نعدّلش القيم، نصلّح الشكل** | ما فيش تعويض للقيم الناقصة ولا حذف لقيم متطرفة | أي تدخل في القيم لازم يكون قرار معلن، مش تنظيف صامت |

## 3.2 ملخص قبل وبعد

| الجدول | قبل (Raw) | بعد (Clean) | اللي اتعمل |
|---|---|---|---|
| `FAOSTAT_data_en_2-23-2026` | 22,568 | **7,185** | فلتر السنين (يبقى 8,985)، ثم فلتر أنواع القياس الثلاثة (يبقى 7,185)، وتسمية `Element` ، وتحويل `Value` إلى `DECIMAL(14,4)` |
| `Irrigated Land_data_en_2-24-2026` | 53 | **53** | فلتر السنين (كل الصفوف جوّه النطاق)، وحذف `Note` لو موجود، وتحويل `Value` إلى `DECIMAL(14,4)` |
| `Rainfall_Monthly_2000_2024` | 79,800 | **79,800** | إزالة التكرار، وتحويل `Rainfall` إلى `DECIMAL(10,2)` |
| `Temperature at 2 Meters_2000_2024` | 79,800 | **79,800** | إزالة التكرار، وتحويل `Temperature` إلى `DECIMAL(10,2)` |
| `Arable Land` | 14,847 | **6,012** | فلتر السنين، وتحويل `Arable_land_percent` إلى `DECIMAL(10,2)` |
| `CO₂ Emissions` | 8,580 | **3,900** | فلتر السنين، وتحويل `CO_Emissions` إلى `DECIMAL(10,2)` |
| `Fertilizer Use` | 12,688 | **5,701** | فلتر السنين، وتحويل `Fertilizer_consumption` إلى `DECIMAL(10,2)` |
| `Population` | 17,195 | **6,625** | فلتر السنين فقط |
| `Metadata_Country_API_SP.POP...` | 265 | **265** | ما اتحذفش أي صف؛ اتضاف تصنيف `Aggregate` و `Is_Aggregate` (في `Dim_Country`) |

الفرق الكبير في جداول البنك الدولي مصدره **الفترة** بس: الجداول دي بتبدأ من 1960/1961/1970، واحنا محتاجين من 2000. الأرقام دي محسوبة من الملفات الأصلية.

## 3.3 الخطوات واحدة واحدة

**① فحص البيانات (Profiling)**

**اللي اتعمل:** عدد الصفوف، القيم المختلفة ( `DISTINCT` ) لكل عمود وصفي، نسبة القيم الفاضية، وتوزيع الـ Flags، قبل أي تعديل.

**ليه:** ما ينفعش نصلّح حاجة قبل ما نفهمها. الفحص ده هو اللي كشف: أن `Value` فيه 288 قيمة مفقودة (Flag `M` )، وأن أنواع القياس 14 مختلفة الوحدات، وأن `Note` مش موجود في جدول SQL.

**② إزالة التكرار**

**اللي اتعمل:** `SELECT DISTINCT *` عند إنشاء كل جدول `clean_` .

**ليه:** حماية من أي صف مكرر. الفحص أثبت إن الملفات مفيهاش تكرار، فالأعداد ما اتغيرتش، لكن لو الملف اتحدّث بتكرار في المستقبل هيتعالج تلقائيًا.

**③ تحديد الفترة 2000–2024**

**اللي اتعمل:** `WHERE Year BETWEEN 2000 AND 2024` في FAOSTAT والري والجداول العالمية الأربعة.

**ليه:** ده نطاق التحليل المطلوب. جدولا المناخ أصلًا 2000–2024 فما احتاجوش فلتر.

**④ اختيار أنواع القياس في FAOSTAT**

**اللي اتعمل:** `Element_Code IN (5312, 5412, 5510)` مع تسميتها: Area Harvested = 5312، Yield = 5412، Production = 5510.

**ليه:** دول الثلاثة اللي بيوصفوا أداء المحصول (مساحة، إنتاجية، إنتاج). الأنواع الـ 11 التانية وحداتها مختلفة تمامًا (أعداد حيوانات، جرام لكل حيوان...) وخلطها معاهم بيخلّي أي جمع بلا معنى.

**⑤ تصحيح أنواع الأعمدة**

**اللي اتعمل:** تحويل `float` إلى `DECIMAL` . في FAOSTAT بـ `TRY_CAST([Value] AS DECIMAL(14,4))` ، وفي الباقي بـ `ALTER COLUMN` .

**ليه:** `float` بيخزّن تقريب (مثال حقيقي: `0.0599999986588955` )، و `DECIMAL` بيخزّن رقم ثابت ( `0.06` ). `TRY_CAST` بترجع `NULL` لو التحويل فشل بدل ما توقف السكريبت. (فيه ملاحظة دقة على CO2 في 3.5.)

**⑥ القيم الفاضية (NULL)**

**اللي اتعمل:** بنسيبها `NULL` . في الجدول المنظّف 24 صف من 7,185: 11 في Area Harvested و 13 في Production و صفر في Yield.

**ليه:** الصفر معناه "الإنتاج فعلًا صفر"، أما `NULL` معناها "مش معروف". لو حطينا صفر هتنخفض المتوسطات غلط. وما مسحناش الصفوف عشان ما نخسرش وجود الصنف في السنة.

**⑦ عمود `Note`**

**اللي اتعمل:** `IF COL_LENGTH(...,'Note') IS NOT NULL ... DROP COLUMN` في جدول الري. وجدول FAOSTAT في SQL أصلًا مفيهوش `Note` .

**ليه:** عمود ملاحظات نصية مش محتاجينه في التحليل. الشرط بيخلّي السكريبت ما يفشلش لو العمود مش موجود.

**⑧ توحيد الدول**

**اللي اتعمل:** أخدنا الـ 265 كود كلهم، وحطينا `Region = 'Aggregate'` للتجمّعات، و `IncomeGroup = 'Not classified'` لإثيوبيا وفنزويلا، وعمود `Is_Aggregate` (0/1).

**ليه:** جداول الحقائق فيها كل الأكواد دي، فلو حذفنا التجمّعات هيفشل الربط أو نخسر بيانات. الأفضل نسيبهم ونعلّمهم، ونفلترهم وقت التحليل.

**⑨ جدول التقويم**

**اللي اتعمل:** جدول `Calendar` بيتولّد بحلقة `WHILE`: 25 سنة × 12 شهر = 300 صف.

**ليه:** المناخ شهري ومحتاج بُعد زمني شهري، والحقائق السنوية محتاجة بُعد سنة (`Dim_Year`).

## 3.4 قرارات اخترنا فيها "ما نعملش"

- **ما عوّضناش القيم الناقصة** (No imputation): الـ `NULL` بتفضل `NULL`.
- **ما حذفناش القيم المتطرفة**: مطر مارس 2021 (حتى 592.58) فضل زي ما هو.
- **ما حذفناش التجمّعات** (مثل `WLD`): اتعلّمت بـ `Is_Aggregate` بدل الحذف.
- **ما حوّلناش الوحدات**: كل عمود في الموديل محتفظ بوحدته الأصلية، وواضحة في اسمه (`_ha`، `_t`، `_1000ha`، `_mm`، `_C`).

## 3.5 تنبيهات تخص التنظيف

**كودا الـ brief: 5111 و 5114**

جدول الأكواد المرجعي في المشروع (الـ brief) فيه الاسمين Irrigated Area و Rainfed Area مقابل الكودين 5111 و 5114. **في الداتا الفعلية** الكودين دول اسمهم Stocks ووحدتهم `An` (أعداد حيوانات، 225 صف) و `No` (نحل، 25 صف)، ومش مساحات ري أو مطر. النسخة الحالية من السكريبت فلترها على **3 أكواد فقط**، وبالتالي الكودين دول **مش داخلين** في `clean_FAOSTAT_data`. المساحة المروية الحقيقية موجودة في `clean_Irrigated_Land`.

**دقة عمود CO2**

السكريبت بيحوّل `CO_Emissions` إلى `DECIMAL(10,2)`. قيم الانبعاثات صغيرة أحيانًا: من 3,900 قيمة، **226 قيمة** بتتقرّب لصفر، و**14.7%** من القيم بيبقى خطأ التقريب فيها أكتر من 5%. لو الدقة مهمة، الأفضل `DECIMAL(12,4)`.

**ملاحظة على `Rainfall` و `Temperature`**

التحويل إلى `DECIMAL(10,2)` بيقرّب لرقمين عشريين. ده مناسب للمطر بالملّيمتر والحرارة بالدرجة، وما بيأثرش على التحليل.

# 4. الموديل: اتبنى إزاي (أهم جزء)

## 4.1 الفكرة: ليه Galaxy Schema؟

في الموديل النجمي (Star Schema) بيبقى فيه جدول حقائق (Fact) في النص، محاط بجداول أبعاد (Dimension). احنا عندنا **4 جداول Fact** بدل واحد، لأن البيانات ليها **4 مستويات تفصيل مختلفة** ووحدات مختلفة، وبيتشاركوا في أبعاد مشتركة. الشكل ده اسمه Galaxy Schema (أو Fact Constellation).

| جدول الحقائق | الـ Grain (الصف = إيه؟) | الأبعاد المرتبطة | القياسات | المصدر |
|---|---|---|---|---|
| `Fact_Crops` | محصول × سنة | `Dim_Item`، `Dim_Year`، `Dim_Country` | المساحة، الإنتاجية، الإنتاج | `clean_FAOSTAT_data` |
| `Fact_Irrigated` | نوع الري × سنة | `Dim_Year`، `Dim_Country` | المساحة، نسبة الأراضي المحصولية | `clean_Irrigated_Land` |
| `Fact_Country_Year` | دولة × سنة | `Dim_Country`، `Dim_Year` | السكان، الأراضي الصالحة، الأسمدة، CO2 | الجداول العالمية الأربعة |
| `Fact_Climate` | موقع × شهر (في سنة) | `Calendar`، `Dim_Location` | المطر، الحرارة | جدولا المناخ |

**ليه مش جدول واحد كبير؟**

لو دمجنا كل حاجة في جدول واحد ونربط بالسنة بس، هيحصل **تضخّم في الصفوف** (Fan-out): كل صف محصول-سنة هيتكرر مع كل صفوف المناخ في السنة دي (266 موقع × 12 شهر = **3,192 صف**)، فالإنتاج هيتجمع 3,192 مرة. وكمان هيبقى فيه أعمدة كتير `NULL` لأن كل مصدر ليه مفاتيح مختلفة. الحل: كل مصدر في جدول Fact بمستوى التفصيل بتاعه، ونقارن بينهم عن طريق **بُعد مشترك** (السنة).

## 4.2 خطوات التصميم الأربعة

1. **نحدد العملية:** تحليل الإنتاج الزراعي والري والمناخ لمصر، ومقارنة مصر بدول العالم في السكان والأسمدة والانبعاثات.
2. **نحدد الـ Grain لكل Fact:** قبل أي عمود. الجدول ده صفه إيه بالظبط؟ (عمود "الـ Grain" في الجدول اللي فوق).
3. **نحدد الأبعاد:** كل "مين / إيه / إمتى / فين" بيتكرر في أكتر من Fact: السنة، الدولة، المحصول، الموقع، الشهر.
4. **نحدد القياسات:** الأعمدة الرقمية اللي بتتجمع أو بتتحلل، ووحدتها في اسم العمود.

## 4.3 شكل الموديل (الصفحة التالية)

الصفحة التالية فيها **رسم الموديل كاملًا**: الجداول والأعمدة والمفاتيح والعلاقات. (PK = مفتاح أساسي، FK = مفتاح أجنبي.)

## AgriTech — Galaxy Schema (4 Facts + 5 Dimensions)




*Dim_Soil_Properties: standalone table (no year / location key) - not part of the model*

## 4.4 الجداول واحد واحد

### أ) جداول الأبعاد (Dimensions)

#### `Calendar` — بُعد الزمن الشهري

| | |
|---|---|
| **الوظيفة** | تقويم شهري: كل شهر من يناير 2000 إلى ديسمبر 2024 |
| **الحجم / الـ PK** | 300 صف (25 × 12) / `YearMonthKey` |
| **بيتبني من** | حلقة `WHILE` في SQL (مفيش ملف مصدر) |
| **ليه؟** | جدولا المناخ شهريان، ومحتاجين مفتاح شهري بصيغة `YEAR * 100 + MONTH` (مثال: مارس 2021 يبقى `202103`) |

| العمود | النوع | المعنى |
|---|---|---|
| `YearNumber` | (FK) INT | السنة — بيربط بـ `Dim_Year` |
| `MonthNumber` | INT | رقم الشهر 1–12 |
| `MonthName` | NVARCHAR(20) | اسم الشهر (بيتولّد بـ `DATENAME`، ولغته حسب لغة الجلسة) |
| `QuarterNumber` | INT | رقم الربع من 1 إلى 4، ويتحسب بالمعادلة `(MONTH - 1) / 3 + 1` |
| `YearMonthKey` | (PK) INT | مفتاح الشهر بصيغة YYYYMM |

#### `Dim_Year` — بُعد السنة

| | |
|---|---|
| **الحجم / الـ PK** | 25 صف (2000–2024) / `YearNumber` |
| **بيتبني من** | `SELECT DISTINCT YearNumber FROM Calendar` |
| **ليه؟** | ده **البُعد المشترك** اللي بيربط الـ Facts السنوية الثلاثة ببعض، وبيتربط بـ `Calendar` عشان يوصّل للمناخ كمان |

| العمود | النوع | المعنى |
|---|---|---|
| `YearNumber` | (PK) INT | السنة |

#### `Dim_Country` — بُعد الدولة

| | |
|---|---|
| **الحجم / الـ PK** | 265 صف (217 دولة + 48 تجمّع) / `Country_Code` |
| **بيتبني من** | جدول `Metadata_Country_...` + أسماء الدول من `clean_Population` (`JOIN` على `Country_Code`) |
| **ليه؟** | بنقفل بكل الأكواد لأن `Fact_Country_Year` فيه تجمّعات وإثيوبيا وفنزويلا. لو حذفناهم كان هيبقى فيه صفوف يتيمة (بدون أصل) في الـ Fact |

| العمود | النوع | المعنى |
|---|---|---|
| `Country_Code` | (PK) NVARCHAR(10) | كود الدولة/التجمّع (مصر = `EGY`) |
| `Country_Name` | نص | اسم الدولة (من `clean_Population`) |
| `Region` | نص | الإقليم، أو `Aggregate` للتجمّعات |
| `IncomeGroup` | نص | فئة الدخل، أو `Aggregate` للتجمّعات، أو `Not classified` (إثيوبيا وفنزويلا) |
| `Is_Aggregate` | (0/1) INT | 1 = تجمّع (مثل `WLD`)، 0 = دولة. استخدمه لفلترة التجمّعات |

### `Dim_Item` — بُعد المنتج

| | |
|---|---|
| **الحجم / الـ PK** | 140 صف / `Item_ID` (رقم تسلسلي) |
| **بيتبني من** | الأسماء المختلفة (`DISTINCT Item`) في `clean_FAOSTAT_data`، مرتّبة أبجديًا بـ `ROW_NUMBER` |
| **ليه؟** | اسم الصنف نص طويل (مثال: Anise, badian, coriander, cumin, caraway, fennel and juniper berries, raw). الربط برقم `INT` أسرع وأأمن من الربط بنص |

| العمود | النوع | المعنى |
|---|---|---|
| `Item_ID` | (PK) INT | رقم تسلسلي للصنف |
| `Item` | نص | اسم الصنف |
| `Item_Type` | نص | `Crop` (78 صنف: ليه Area Harvested) أو `Livestock / Processed product` (62 صنف: ليه Production فقط) |

### `Dim_Location` — بُعد الموقع

| | |
|---|---|
| **الحجم / الـ PK** | 266 صف / `Location_ID` |
| **بيتبني من** | أزواج `(LAT, LON)` المختلفة من **جدولي المناخ معًا** (`UNION`) |
| **ليه؟** | ربط الـ Fact برقم `INT` بدل زوج أرقام عشرية (`float`). ومصدره الجدولين مع بعض عشان ما يعتمدش على جدول واحد بس |

| العمود | النوع | المعنى |
|---|---|---|
| `Location_ID` | (PK) INT | رقم تسلسلي للموقع (مرتّب حسب `LAT` ثم `LON`) |
| `LAT` | float | خط العرض |
| `LON` | float | خط الطول |

## ب) جداول الحقائق (Facts)

### `Fact_Crops` — المحاصيل

| | |
|---|---|
| **الـ Grain / الـ PK** | محصول × سنة / `(Item_ID, YearNumber)` |
| **الحجم** | 3,381 صف |
| **بيتبني من** | `clean_FAOSTAT_data` عن طريق **Pivot**: `GROUP BY` الصنف والسنة، وكل نوع قياس في عمود |
| **ليه Pivot؟** | الأصل Long format فيه قياسات بوحدات مختلفة في عمود `Value` واحد. بعد الـ Pivot كل قياس في عمود باسم ووحدة واضحين، فما ينفعش حد يجمع هكتار مع طن بالغلط |

| العمود | النوع | المعنى |
|---|---|---|
| `Country_Code` | (FK) NVARCHAR(10) | ثابت `EGY` (لأن FAOSTAT جاي لمصر بس). موجود عشان الـ Fact يتربط بـ `Dim_Country` |
| `Item_ID` | (FK, PK) INT | المنتج — بيربط بـ `Dim_Item` |
| `YearNumber` | (FK, PK) INT | السنة — بيربط بـ `Dim_Year` |
| `Area_Harvested_ha` | DECIMAL(14,4) | المساحة المحصودة بالهكتار (الكود 5312) |
| `Yield_kg_per_ha` | DECIMAL(14,4) | الإنتاجية كجم/هكتار (الكود 5412) |
| `Production_t` | DECIMAL(14,4) | الإنتاج بالطن (الكود 5510) |

**ليه `MAX` في الـ Pivot؟**

كل (صنف، سنة، نوع قياس) بيظهر مرة واحدة بالظبط، فـ `MAX(CASE WHEN ...)` بيختار القيمة الوحيدة وبيتجاهل `NULL`. ما بيحصلش تجميع فعلي. والـ `NULL` في `Area_Harvested_ha` و `Yield_kg_per_ha` لأصناف الـ 62 غير المحاصيل **متوقع** (مالهمش مساحة).

### `Fact_Irrigated` — الري

| | |
|---|---|
| **الـ Grain / الـ PK** | نوع الري × سنة / `(Irrigation_Type, YearNumber)` |
| **الحجم** | 29 صف: 24 لنوع equipped و 5 لنوع actually irrigated |
| **بيتبني من** | `clean_Irrigated_Land` بـ Pivot على `Element` (`Area` و `Share in Cropland`) |

| العمود | النوع | المعنى |
|---|---|---|
| `Country_Code` | (FK) NVARCHAR(10) | ثابت `EGY` |
| `YearNumber` | (FK, PK) INT | السنة |
| `Irrigation_Type` | (PK) NVARCHAR(100) | Land area equipped for irrigation<br>أو<br>Land area actually irrigated |
| `Area_1000ha` | DECIMAL(14,4) | المساحة بالألف هكتار |
| `Share_In_Cropland_pct` | DECIMAL(14,4) | النسبة المئوية من الأراضي المحصولية. موجودة لنوع equipped فقط، و`NULL` للنوع التاني |

### `Fact_Country_Year` — مؤشرات الدول

| | |
|---|---|
| **الـ Grain / الـ PK** | دولة × سنة / `(Country_Code, YearNumber)` |
| **الحجم** | 6,625 صف = 265 كود × 25 سنة |
| **بيتبني من** | `clean_Population` كعمود فقري (Spine)، ثم `LEFT JOIN` مع الأراضي والأسمدة والانبعاثات على `(Country_Code, Year)` |
| **ليه Population هو الفقري؟** | لأنه الأشمل: كل الأكواد وكل السنين. اتحقّقنا إن كل مفاتيح الجداول التلاتة التانية **جوّه** مفاتيحه (صفر مفتاح برّه). فـ `LEFT JOIN` ما بيخسّرش أي صف، و `INNER JOIN` كان هيحذف صفوف الدول اللي ناقصة قياس |

| العمود | النوع | المعنى | القيم الفاضية |
|---|---|---|---|
| `Country_Code` | (FK, PK) NVARCHAR(10) | كود الدولة | — |
| `YearNumber` | (FK, PK) INT | السنة | — |
| `Population` | رقم | إجمالي السكان | 0 |
| `Arable_Land_pct` | DECIMAL(10,2) | الأراضي الصالحة للزراعة (% من مساحة الأرض) | 613 |
| `Fertilizer_kg_per_ha` | DECIMAL(10,2) | استهلاك الأسمدة (كجم لكل هكتار أرض صالحة) | 924 |
| `CO2_Agriculture_Mt` | DECIMAL(10,2) | انبعاثات CO2 من الزراعة (Mt CO2e) | 2,725 |

الفاضي هنا **مش خطأ**: الأراضي والأسمدة بتقف عند 2023 (سنة 2024 فاضية)، والانبعاثات ليها 156 كود بس.

### `Fact_Climate` — المناخ

| | |
|---|---|
| **الـ Grain / الـ PK** | موقع × شهر / `(YearMonthKey, Location_ID)` |
| **الحجم** | 79,800 صف = 266 موقع × 300 شهر |

| | |
|---|---|
| **بيتبني من** | `JOIN` بين `clean_Rainfall_Monthly` و `clean_Temperature_at2Meters` على `(YEAR, Month, LAT, LON)`، ثم `JOIN` مع `Dim_Location` |
| **تحويل الشهر** | الشهر جاي نص (`JAN`...`DEC`). بناخد أول 3 حروف ونحوّلها لرقم 1–12 بـ `CASE`، ونركّب المفتاح بالمعادلة `YEAR * 100 + MONTH` |

| العمود | النوع | المعنى |
|---|---|---|
| `YearMonthKey` | INT (FK, PK) | مفتاح الشهر YYYYMM — بيربط بـ `Calendar` |
| `Location_ID` | INT (FK, PK) | الموقع — بيربط بـ `Dim_Location` |
| `Rainfall_mm` | DECIMAL(10,2) | مجموع المطر الشهري (الوحدة مفترضة ملّيمتر) |
| `Temperature_C` | DECIMAL(10,2) | متوسط الحرارة على 2 متر (الوحدة مفترضة مئوية) |

> **انتبه لـ `ELSE 1` في تحويل الشهر**
>
> السكريبت بيحوّل أي اسم شهر غير معروف إلى **يناير** بدل ما يفشل. اتأكدنا إن القيم الفعلية 12 قيمة فقط (`JAN`...`DEC`) فمفيش مشكلة حاليًا، لكن لو الملف اتغيّر هيحصل خطأ صامت.

## 4.5 العلاقات (Foreign Keys)

كل علاقة **متعدد إلى واحد** (N : 1): الجدول التابع (Fact أو `Calendar`) بيشاور على جدول البُعد. وكلها **مفروضة فعليًا** في SQL Server بقيود `FOREIGN KEY`، يعني أي قيمة مالهاش أصل بيفشل معاها إنشاء القيد وبتظهر رسالة خطأ في تبويب Messages.

| # | اسم القيد | من (N) | إلى (1) |
|---|---|---|---|
| 1 | `FK_Calendar_Year` | `Calendar.YearNumber` | `Dim_Year.YearNumber` |
| 2 | `FK_Fact_Crops_Country` | `Fact_Crops.Country_Code` | `Dim_Country.Country_Code` |
| 3 | `FK_Fact_Crops_Item` | `Fact_Crops.Item_ID` | `Dim_Item.Item_ID` |
| 4 | `FK_Fact_Crops_Year` | `Fact_Crops.YearNumber` | `Dim_Year.YearNumber` |
| 5 | `FK_Fact_Irrigated_Country` | `Fact_Irrigated.Country_Code` | `Dim_Country.Country_Code` |
| 6 | `FK_Fact_Irrigated_Year` | `Fact_Irrigated.YearNumber` | `Dim_Year.YearNumber` |
| 7 | `FK_Fact_Country_Year_Country` | `Fact_Country_Year.Country_Code` | `Dim_Country.Country_Code` |
| 8 | `FK_Fact_Country_Year_Year` | `Fact_Country_Year.YearNumber` | `Dim_Year.YearNumber` |
| 9 | `FK_Fact_Climate_Calendar` | `Fact_Climate.YearMonthKey` | `Calendar.YearMonthKey` |
| 10 | `FK_Fact_Climate_Location` | `Fact_Climate.Location_ID` | `Dim_Location.Location_ID` |

> **الأبعاد المشتركة (Conformed Dimensions) — سر المقارنة بين المصادر**
>
> - `Dim_Year` بيربط `Fact_Crops` و `Fact_Irrigated` و `Fact_Country_Year` مباشرة، وبيوصل لـ `Fact_Climate` بشكل غير مباشر عن طريق `Calendar`. عشان كده نقدر نقارن **إنتاج القمح بالمطر أو بعدد السكان** على أساس السنة.
> - `Dim_Country` بيربط 3 Facts، وده بيسمح بتوسيع الموديل لدول تانية من غير تغيير في البنية.
> - مفيش علاقة مباشرة بين `Fact_Crops` و `Fact_Climate`: المقارنة بينهم بتتم **بعد تجميع كل واحد على مستوى السنة** (الأمثلة في 4.8).

## 4.6 ترتيب البناء ولية بالترتيب ده

**القاعدة:** الأبعاد قبل الحقائق. لأن الـ `FOREIGN KEY` لازم جدول الأصل يكون موجود وفيه المفاتيح قبل ما الجدول التابع يتعمل.

| # | الخطوة | بتحتاج إيه؟ | ليه هنا؟ |
|---|---|---|---|
| 0 | فك القيود ثم حذف القديم | — | الـ Facts الأول ثم الأبعاد، وإلا القيود ترفض الحذف. ده اللي بيخلّي السكريبت يتعاد |
| 1 | جداول `clean_...` (أقسام 01–04 و 06–09) | الجداول الخام | كل ما بعدها بيقرا منها |
| 2 | `Calendar` (قسم 05) | — | بيتولّد بالكود، ومحتاجينه لـ `Dim_Year` و `Fact_Climate` |
| 3 | `Dim_Country` (قسم 10) | `Metadata` + `clean_Population` | محتاج قبل أي Fact فيه `Country_Code` |
| 4 | `Dim_Year` (قسم 11) | `Calendar` | وبعده بنضيف `FK_Calendar_Year` |
| 5 | `Dim_Item` (قسم 12) | `clean_FAOSTAT_data` | محتاج قبل `Fact_Crops` |
| 6 | `Dim_Location` (قسم 13) | جدولا المناخ | محتاج قبل `Fact_Climate` |
| 7 | `Fact_Crops` (قسم 14) | `Dim_Item` + `Dim_Country` + `Dim_Year` | بعد كل أبعاده |
| 8 | `Fact_Irrigated` (قسم 15) | `Dim_Year` + `Dim_Country` | — |
| 9 | `Fact_Country_Year` (قسم 16) | `Dim_Year` + `Dim_Country` | — |
| 10 | `Fact_Climate` (قسم 17) | `Dim_Location` + `Calendar` | آخر واحد |

### نمط بناء أي Fact (4 أوامر بنفس الترتيب)

1. `SELECT ... INTO Fact_X` — بينشئ الجدول ويملاه.
2. `ALTER COLUMN ... NOT NULL` — لأن `SELECT INTO` بيعمل الأعمدة تقبل `NULL`، والـ `PRIMARY KEY` بيرفضها.
3. `ADD CONSTRAINT ... PRIMARY KEY` — بيضمن إن الـ Grain مش متكرر (لو فيه تكرار، إنشاء القيد هيفشل وتظهر رسالة خطأ، وده المطلوب).
4. `ADD CONSTRAINT ... FOREIGN KEY` — بيضمن إن كل مفتاح ليه أصل في جدول البُعد.

> **ليه فيه `GO` بين الأقسام؟**
> كل قسم بيتعمل في **دفعة (Batch) مستقلة**. SQL Server بيفحص أسماء الأعمدة قبل التشغيل، فلو الجدول القديم موجود بأعمدة مختلفة، الفحص بيفشل لكل الدفعة. مع `GO` كل دفعة بتتفحص بعد ما اللي قبلها اتنفذ.

## 4.7 قرارات التصميم ولية

| القرار | البديل | ليه اخترنا ده؟ |
|---|---|---|
| 4 جداول Facts | جدول واحد كبير | مستويات تفصيل ووحدات مختلفة. الجدول الواحد بيسبب Fan-out وأرقام مكرّرة |
| Pivot لأنواع القياس في `Fact_Crops` | إبقاء `Element` + `Value` | ما يتجمعش هكتار مع طن. كل قياس بوحدته في اسم عمود |
| مفتاح رقمي `Item_ID` | الربط بنص `Item` | ربط أسرع وأأمن، والاسم الطويل ما بيتكرّرش في الـ Fact |
| مفتاح رقمي `Location_ID` | الربط بـ `LAT` و `LON` | المقارنة على `float` ممكن تفشل لو الدقة اتغيّرت |
| `Population` كعمود فقري بـ `LEFT JOIN` | `INNER JOIN` بين الجداول | الـ `INNER JOIN` بيحذف الدول اللي ناقصة أي مؤشر |
| إبقاء التجمّعات + `Is_Aggregate` | حذفها | كل الأكواد موجودة في الـ Facts. التعليم أأمن من الحذف |
| `Country_Code = EGY` ثابت في `Fact_Crops` و `Fact_Irrigated` | ترك الـ Fact بدون دولة | الربط بـ `Dim_Country` ومقارنة مصر بغيرها لاحقًا |

| القرار | البديل | ليه اخترنا ده؟ |
|---|---|---|
| `Dim_Location` من جدولي المناخ معًا (`UNION`) | من جدول المطر فقط | ما نعتمدش على جدول واحد. لو واحد فاضي الأبعاد تفضل شغّالة |
| قيود `PK` و `FK` فعلية | من غير قيود | الجودة بتتفرض تلقائيًا: أي تكرار أو مفتاح يتيم بيفشّل إنشاء القيد وتظهر رسالة خطأ |
| `Year` رقم صحيح بدل تاريخ | عمود تاريخ | كل المصادر سنوية أو (سنة + شهر). ما فيش يوم |

## 4.8 التحقق وأمثلة استعلامات

### الأرقام المتوقعة بعد التشغيل

| الجدول | الصفوف | الفترة | الجدول | الصفوف | الفترة |
|---|---|---|---|---|---|
| `clean_FAOSTAT_data` | 7,185 | 2000–2024 | `Dim_Country` | 265 | — |
| `clean_Irrigated_Land` | 53 | 2000–2023 | `Dim_Item` | 140 | — |
| `clean_Rainfall_Monthly` | 79,800 | 2000–2024 | `Dim_Location` | 266 | — |
| `clean_Temperature_at2Meters` | 79,800 | 2000–2024 | `Dim_Year` | 25 | 2000–2024 |
| `clean_Arable_Land` | 6,012 | 2000–2023 | `Fact_Crops` | 3,381 | 2000–2024 |
| `clean_CO2Emissions` | 3,900 | 2000–2024 | `Fact_Irrigated` | 29 | 2000–2023 |
| `clean_Fertilizer_Use` | 5,701 | 2000–2023 | `Fact_Country_Year` | 6,625 | 2000–2024 |
| `clean_Population` | 6,625 | 2000–2024 | `Fact_Climate` | 79,800 | 2000–2024 |
| `Calendar` | 300 | 2000–2024 | | | |

وكمان: كويري `Element_Code / Element / Unit` على `clean_FAOSTAT_data` لازم ترجّع **3 صفوف**: 5312 (Area Harvested، 1,908 صف)، 5412 (Yield، 1,896 صف)، 5510 (Production، 3,381 صف).

### مثال 1: القمح في مصر (آخر 3 سنين)

```
select
    f.YearNumber,
    f.Area_Harvested_ha,
    f.Yield_kg_per_ha,
    f.Production_t
from Fact_Crops f
join Dim_Item i
    on i.Item_ID = f.Item_ID
where i.Item = 'Wheat'
and f.YearNumber >= 2022
order by
    f.YearNumber
```

| YearNumber | Area_Harvested_ha | Yield_kg_per_ha | Production_t |
|---|---|---|---|
| 2022 | 1,436,510 | 6,698.9 | 9,622,993 |
| 2023 | 1,337,698 | 6,776.9 | 9,065,380 |
| 2024 | 1,386,892 | 6,777.7 | 9,400,000 |

### مثال 2: متوسط الحرارة والمطر السنوي (مقارنة بين Fact و Calendar)

```
select
    c.YearNumber,
    avg(f.Temperature_C) as Avg_Temp_C,
    avg(f.Rainfall_mm) * 12 as Avg_Annual_Rain_mm -- mean monthly rain per grid point x 12
from Fact_Climate f
join Calendar c
    on c.YearMonthKey = f.YearMonthKey
group by
    c.YearNumber
order by
    c.YearNumber
```

نتيجة السنين 2000 / 2012 / 2024: الحرارة 21.35 / 22.10 / 23.00، والمطر السنوي (متوسط النقطة) 27.7 / 20.7 / 30.7 ملم.

### مثال 3: الربط بين محصول وسكان (بُعد السنة المشترك)

```
select
    f.YearNumber,
    f.Production_t,
    p.Population,
    f.Production_t * 1000.0 / p.Population as Wheat_kg_per_person
from Fact_Crops f
join Dim_Item i
    on i.Item_ID = f.Item_ID
join Fact_Country_Year p
    on p.YearNumber = f.YearNumber
    and p.Country_Code = f.Country_Code
where i.Item = 'Wheat'
order by
    f.YearNumber
```

نتيجة 2000 / 2012 / 2024: 89.8 / 94.4 / 80.7 كجم قمح لكل فرد. (إنتاج فقط، من غير استيراد أو تصدير.)

> **عن الأمثلة**
> الأرقام دي محسوبة من نفس الملفات الأصلية بنفس منطق الاستعلام، مش من تشغيل على SQL Server عندك.

## 4.9 الاستخدام في التحليل (وأدوات BI مثل Power BI)

- اعمل العلاقات **من البُعد إلى الـ Fact** (واحد إلى متعدد) بنفس القيود الموجودة في 4.5، باتجاه فلترة واحد من البُعد للـ Fact.
- استخدم `Dim_Year` كمحور زمني لأي رسم بيقارن أكتر من Fact. واستخدم `Calendar` لو محتاج الشهر أو الربع (المناخ).
- **الإنتاجية ما تتجمعش:** احسبها `Production_t × 1000 ÷ Area_Harvested_ha` على المستوى اللي عايزه، بدل ما تجمع أو تتوسّط `Yield_kg_per_ha`.
- لرسوم المساحة والإنتاجية، فلتر `Dim_Item.Item_Type = 'Crop'`. الأصناف الـ 62 التانية ليها إنتاج بس.
- لترتيب الدول أو متوسطاتها، فلتر `Dim_Country.Is_Aggregate = 0` عشان ما يتخلطش العالم مع الدول.
- الأعمدة الفاضية (`NULL`) في `Fact_Country_Year` متوقعة لسنة 2024 (الأراضي والأسمدة) وللدول اللي ما لهاش انبعاثات.

## 4.10 الافتراضات والقيود

| البند | التأثير |
|---|---|
| وحدات المناخ (ملّيمتر ودرجة مئوية) **مفترضة** من القيم | الملفات ما بتذكرش الوحدة. تأكّد من المصدر لو هتنشر الأرقام |
| مطر مارس 2021 (حتى 592.58) قيم متطرفة | بتأثر على المتوسطات والقيم القصوى. مراجعتها مطلوبة |
| "المساحة المروية فعلًا" لـ 5 سنين فقط (2019–2023) | ما ينفعش تحليل اتجاه طويل عليها |

| البند | التأثير |
|---|---|
| الأراضي والأسمدة والري بتقف عند 2023 | سنة 2024 = `NULL` في `Fact_Country_Year`، ومفيش صف ري لـ 2024 |
| 62 صنف مش محاصيل في `Fact_Crops` | استخدم `Item_Type` وإلا الإجماليات هتخلط منتجات مصنّعة بمحاصيل |
| `Country_Code = EGY` ثابت | صح لأن FAOSTAT مصر فقط. لو أُضيفت دول لازم يتغير |
| `Item_ID` و `Location_ID` مرتّبين أبجديًا/جغرافيًا | لو أُضيفت أصناف أو مواقع، الأرقام هتتغيّر بعد إعادة التشغيل. ما تخزّنهاش برّه |
| `Dim_Soil_Properties` خارج الموديل | مفيش سنة أو موقع للربط بيه |
| كودا 5111 و 5114 خارج النسخة الحالية | اتشرح في 3.5 |
| `DECIMAL(10,2)` على `CO_Emissions` | فقد دقة في القيم الصغيرة (3.5) |
| `MonthName` بيعتمد على لغة الجلسة | ممكن يطلع بالإنجليزي أو العربي حسب إعدادات السيرفر |

# 5. ملحق

## 5.1 الكود الأساسي لأهم جداول الموديل

صيغة مبسّطة (كل كلمة أساسية في سطر) من السكريبت الأصلي.

**`Dim_Item`**

```
select
    cast(row_number() over (order by i.Item) as int) as Item_ID,
    i.Item,
    case
        when a.Item is not null then 'Crop'
        else 'Livestock / Processed product'
    end as Item_Type -- crop = has Area harvested
into Dim_Item
from (
    select distinct Item
    from clean_FAOSTAT_data
) i
left join (
    select distinct Item
    from clean_FAOSTAT_data
    where Element_Code = 5312
) a
    on a.Item = i.Item
```

**`Fact_Crops` (الـ Pivot)**

```
select
    cast('EGY' as nvarchar(10)) as Country_Code,
    i.Item_ID,
    cast(c.Year as int) as YearNumber,
    max(case when c.Element_Code = 5312 then c.[Value] end) as Area_Harvested_ha,
    max(case when c.Element_Code = 5412 then c.[Value] end) as Yield_kg_per_ha,
    max(case when c.Element_Code = 5510 then c.[Value] end) as Production_t
into Fact_Crops
from clean_FAOSTAT_data c
join Dim_Item i
    on i.Item = c.Item
group by
    i.Item_ID,
    c.Year
```

### `Fact_Climate` (تحويل الشهر + الربط)

```
select
    cast(r.[YEAR] as int) * 100
        + case upper(left(ltrim(r.[MONTH]), 3))
            when 'JAN' then 1 when 'FEB' then 2 when 'MAR' then 3
            when 'APR' then 4 when 'MAY' then 5 when 'JUN' then 6
            when 'JUL' then 7 when 'AUG' then 8 when 'SEP' then 9
            when 'OCT' then 10 when 'NOV' then 11 when 'DEC' then 12
            else 1
        end as YearMonthKey,
    l.Location_ID,
    r.Rainfall as Rainfall_mm,
    t.Temperature as Temperature_C
into Fact_Climate
from clean_Rainfall_Monthly r
join clean_Temperature_at2Meters t
    on t.[YEAR] = r.[YEAR]
    and t.[MONTH] = r.[MONTH]
    and t.LAT = r.LAT
    and t.LON = r.LON
join Dim_Location l
    on l.LAT = r.LAT
    and l.LON = r.LON
```

### `Dim_Country`

```
select
    cast(m.Country_Code as nvarchar(10)) as Country_Code,
    n.Country_Name,
    coalesce(m.Region, 'Aggregate') as Region,
    case
        when m.Region is null then 'Aggregate'
        else coalesce(m.IncomeGroup, 'Not classified')
    end as IncomeGroup,
    case when m.Region is null then 1 else 0 end as Is_Aggregate
into Dim_Country
from [dbo].[Metadata_Country_API_SP.POP.TOTL_DS2_en_csv_v2_40826] m
join (
    select distinct
        Country_Code,
        Country_Name
    from clean_Population
) n
    on n.Country_Code = m.Country_Code
```

## 5.2 ملاحظات قبل تشغيل السكريبت

**نقاط لازم تعرفها**

- شغّل السكريبت **كله من أول سطر** (فيه `GO` بين الأقسام). ما تشغّلش قسم لوحده لأن الأقسام معتمدة على بعض.
- أول السكريبت فيه `DROP TABLE IF EXISTS Dim_Soil_Properties`. لو ده الجدول اللي استوردته من ملف التربة، **هيتمسح**. لو محتاجه، شيل السطر ده أو استورده تاني بعد التشغيل.
- السكريبت بيعتمد على أسماء الأعمدة كما ظهرت في SSMS: `Element_Code` و `Item_Code_CPC` و `Area_Code_M49` و `Year_Code`. أي اختلاف هيظهر كخطأ `Invalid column name`.
- الأحمر (الخطوط الحمراء تحت الأسماء) في SSMS قبل التشغيل طبيعي: بيبقى لأن الجداول لسه ما اتعملتش. اضغط `Ctrl+Shift+R` لتحديث الـ IntelliSense بعد التشغيل.